QIRE – Was in der letzten Woche passiert ist

Zeitraum 29.10.–05.11.2026 · erstellt am 05.11.2026 aus den Commits und Dateien im Repo

1. Kurzfassung

- **29.–30.10.:** Späher-Recherche („Recherche-Strom“): rund 20 Recherchedurchläufe zu Quantisierung, Rotationen, Gittern, Energie, Tensornetzen und mehr.
- **02.11.:** Neuer Plan: zuerst eine **Wissensbasis** (`WISSEN/`), dann kreativer Neustart. In einem Tag 6 Recherche-Wellen. Ergebnis: **818 Quellen in 22 Themenfeldern**, alle Felder gesättigt.
- **02.11.:** Aus der Wissensbasis: **9 geprüfte Schlüsse** (S-001–S-009) und **9 neue Wege** (W1–W9). Kernschluss: Rotation (Hadamard) wirkt wie eine billige Skala, ist aber kein eigener Vorteil.
- **02.–03.11.: Phase 2** (Kreativ-Neustart) freigegeben. In drei Runden wurden fünf Wege getestet, nur mit Vortests auf Tuning-Seeds: W5, W6, W2, W4 und W7.
- **Wichtigster Fund:** Ein Codebuch aus Quantenstruktur (Clifford-artige Gruppe, „Orbit-8D“) ist bei echten Gewichten **gleichwertig mit dem E8-Gitter** und deutlich besser als einfache Quantisierer.
- **03.11.:** Zwei Läufe vorregistriert und von dir freigegeben: **I-050** (Orbit-Codebuch gegen E8) und **I-051** (byte-faire Messreihe, das geplante Rückgrat der Arbeit). Gerechnet werden sie auf dem MPCDF-Cluster (Raven). Ergebnisse liegen noch nicht im Repo.
- **Verworfen:** W4 (Rotation im Gradientenpfad) und W7 (Quadrat-Aktivierungen). Bei W5 (Bitflips) bleibt nur eine Randnotiz.

2. Hintergrund: Warum die Woche so aussah

Das Ziel von QIRE ist eine quanten-inspirierte, ressourceneffiziente KI. Gemeint ist eine KI, die mit weniger Speicher (Bytes), weniger Rechenoperationen (FLOPs) oder weniger Energie gleich gut arbeitet. Ideen aus der Quantenphysik dienen als Werkzeug, zum Beispiel unitäre Rotationen, Stabilisatorzustände oder Tensornetze.

Die Ausgangslage vor dieser Woche:

- **I-038** hatte gezeigt, dass die Wirkung von QIRE klassisch ist. Deshalb heißt es ehrlich „quanten-inspiriert“, nicht „Quantenvorteil“.
- Die Erkundungen Z1–Z3 (Ende Oktober) zeigten: Gegen *faire* Gegner liegt die Hadamard-Rotation nur gleichauf. Faire Gegner sind Gruppenskala, Lloyd-Gitter und QAT, gemessen bei gleich vielen Bytes. Frühere „Gewinne“ kamen teils von zu kurzem Training oder von falscher Zählung (I-045-v4, I-049).
- Daraus entstand die Kreativ-Methode vom 27.10. Sie setzt auf viele Ideen, harte Kontrollen und dein Bauchgefühl als festes Kontingent. Dazu kam eine harte Regel: Gezählt wird nur ein Vorteil **bei gleichen Bytes oder gleichen FLOPs, mit genug Training**.

Deine Entscheidung am 02.11.: Bevor neue Ideen entstehen, soll alles, was auch nur entfernt relevant ist, dokumentiert werden. Neue Ideen sollen also auf belegtem Wissen

stehen, nicht auf dem Gedächtnis der KI. Jede Idee muss die nächste bekannte Arbeit zitieren und gegen den stärksten Gegner aus der Literatur antreten.

3. Im Detail

3.1 Späher-Recherche (29.–30.10.)

Automatische Späher suchten laufend nach neuen Arbeiten und schrieben die Funde in `recherche/zyklus/STROM.md`. Themen waren unter anderem FP4-Training, KV-Cache-Quantisierung, Gitter- und Trellis-Codebücher, Energie je Token, Hadamard-MLP, Tensornetz-Kompression und Seed-Gewichte. Am 02.11. kam alles nach `main`. Der Branch liegt jetzt als Archiv. Die Späher sind deaktiviert, aber nicht gelöscht; gearbeitet wird nur noch auf deinen Zuruf.

3.2 Wissensbasis (Phase 1, 02.11.)

- **Aufbau:** Ordner `WISSEN/` mit `quellen.json` (eine Zeile je Quelle: Kernaussage, Zahlen, Quantenbezug, Bezug zu eigenen Befunden), einer Datei je Themenfeld, einem Prüfskript und `INDEX.md`.
- **Welle 0:** Der alte Bestand (bib, Notizen, Späher-Funde) wurde übernommen und über arXiv-Metadaten bereinigt, etwa 530 Quellen.
- **Wellen 1–5:** Je Feld recherchierte ein Agent. Die 22 Felder sind:
  Kern: Gewichts- und Aktivierungsquantisierung, Rotationen, Gitter/Codebücher, Tensornetze, quanten-inspirierte ML, strukturierte Matrizen, ternäres Training.
  Nachbarn: Skalengesetze, effiziente Architekturen, Distillation, Sparsity, Energie/Hardware, Zufallsgewichte, Aktivierungsfunktionen, Informationsgrenzen.
  Fernfelder: Quantenfehlerkorrektur, Renormierungsgruppe, Signalverarbeitung, Neurobiologie, offene Quantensysteme, Physik-Simulation.
- **Sättigung:** Ein Feld gilt als gesättigt, wenn zwei Runden hintereinander weniger als 10 % neue Quellen bringen. Am Ende standen alle Felder bei 0–8 % neuen Quellen, insgesamt **818 Quellen**. Damit war Phase 1 abgeschlossen.
- Zahlen aus Abstracts gelten als *ungeprüft*, bis sie im Volltext stehen. Im Volltext gelesen ist bisher nur ein kleiner Teil, etwa 80 Quellen.

3.3 Schlüsse und Wege (Querschnitte 1 und 2)

Schluss	Inhalt (vereinfacht)
S-001	Rotation glättet Ausreißer. Das schaffen Gruppenskalen oder Lloyd-Gitter genauso, also ist Rotation „eine teure Gruppenskala“. Haltbar ist der Anspruch, dass sie ein gleichwertiger, strukturell begründeter Weg ist.
S-002	Jeder Anspruch braucht eine feste Liste der stärksten Gegner, gleiche Bytes *inklusive Skalen und Codebuch* und mindestens zwei Trainingslängen.
S-003	**Lücke in der Literatur:** Byte-faire Vergleiche an kleinen Modellen auf der CPU fehlen fast völlig. Das kann QIREs eigener Beitrag werden.
S-004	Effizienz heißt vor allem Bytes; die Energie folgt beim Dekodieren den Speicherzugriffen.
S-005	Strukturierte FFN-Schichten (TT, Monarch, Fastfood) verlieren naiv, können aber mit passender Initialisierung gewinnen. Das ist noch offen.
S-006	Die Quadrat-Aktivierung (Born-Regel-Analogie) bringt keinen eigenen Vorteil; ReLU² ist konkurrenzfähig.

S-007	Neue, noch ungetestete Einsatzorte der Rotation sind Bitflip-Robustheit und der Gradientenpfad.
S-008	Ehrlicher Quantenrahmen für die schriftliche Arbeit.
S-009	Die Perplexität (bpc) kann einen Funktionsverlust verdecken. Deshalb braucht es zusätzlich eine Aufgabenmetrik.

Daraus wurden die Wege W1–W9 abgeleitet: W1 Betriebskosten, W2 byte-faire Messreihe, W3 strukturierte FFN, W4 Rotation im Gradientenpfad, W5 Bitflips, W6 Clifford-Codebuch, W7 Quadrat-Aktivierungen, W8 Seed-Gewichte, W9 Multiskala/MERA.

3.4 Phase 2: Kreativ-Neustart (02.–03.11.)

Jede Runde lief nach demselben Ablauf: Agenten erzeugen Ideen, Opus prüft sie und lässt höchstens zwei weiter, dann folgt ein Vortest von höchstens 30 Minuten nur auf **Tuning-Seeds**. Nur was danach noch trägt, wird vorregistriert, und zwar erst nach deiner Freigabe.

Weg	Was getestet wurde	Ergebnis (Erkundung, kein Befund)	Entscheidung
W5 Bitflips	MNIST-MLP: einzelne gespeicherte Bits kippen zufällig. Verglichen wurden Rotation, Clipping und g16.	Bei 4 Bit liegen Rotation und Clipping gleichauf, bei 2 Bit ist Clipping besser. g16 ist anfällig, weil es so viele fp16-Skalen hat.	keine Vorregistrierung; Randnotiz „Skalen sind die Angriffsfläche“
W6 Clifford-Codebuch	Codebuch als Bahn (Orbit) gelernter Vektoren unter einer Clifford-artigen Gruppe in 8 Dimensionen, verglichen mit dem E8-Gitter.	Synthetisch: Orbit +1,24 dB, E8 +1,13 dB. Am echten Byte-LM bei 2,1 Bit/Gewicht: Orbit 2,516 bpc, E8 2,529, Lloyd-1D 2,847. Das Kerdock-Winkelbuch ist tot.	**→ I-050**
W2 byte-faire Messreihe	Rate-Güte-Kurve: Alle Bytes werden gezählt (Indizes, Skalen, Codebuch). Dazu ein kleineres Modell als Gegner.	Bei ≥ 3 Bit sind alle Verfahren fast gleich. Das kleinere fp16-Modell ist überraschend konkurrenzfähig. T = 1000 Schritte ist zu kurz. Der Kopiertest als Aufgabenmetrik funktioniert nicht.	**→ I-051**
W4 Rotation im Gradientenpfad	4-Bit-Training mit und ohne Hadamard vor dem Gewichtsgradienten	Keine Instabilität, die Rotation könnte also nichts retten. Clipping liegt vorn, Rotation kostet 13–15 % mehr Zeit.	zurückgestellt
W7 Quadrat-Familie	z^2, ReLU^2, $\lvert z\rvert$, GELU und SwiGLU unter 4-Bit-Aktivierungen	Mit Hadamard verhalten sich alle Aktivierungen gleich. Die Kurtosis sagt den Verlust nicht voraus.	verworfen, höchstens Nebenfaktor

Ein Nebenbefund aus W6: Die reale Clifford-Gruppe liegt **nicht** in der Symmetriegruppe von E8. Orbit-Codebuch und E8 sind also wirklich verschiedene Konstruktionen. Die ehrliche,

langweiligste Erklärung bleibt trotzdem: Der Gewinn kommt aus der Packung in 8 Dimensionen, nicht speziell aus der Quantenstruktur.

3.5 Die zwei freigegebenen Läufe (03.11.)

I-050 – Orbit-Codebuch gegen E8. Frage: Sind beide bei gleichen Bytes gleichwertig? Der Äquivalenztest (TOST) gilt als bestanden, wenn die Differenz unter 0,02 bpc liegt. Weitere Gegner sind Hadamard+Lloyd, Lloyd-1D und g16 mit 8-Bit-Skalen. Aufbau: 2 und 3 Bit pro Gewicht, 2 Trainingslängen (4000 und 8000 Schritte), Mess-Seeds 3000–3004.

I-051 – Byte-faire Messreihe (Rückgrat der Arbeit). Es gibt 11 Arme, darunter Lloyd, Hadamard, g16/g32, GPTQ-artig, E8, Orbit, MSB und ein kleineres Modell. Gerechnet wird mit 4 Trainingslängen (2000–16000) und den Mess-Seeds 3100–3104. Gemessen werden bpc gegen die Bytes und als Aufgabe die Wortvervollständigung (deine Wahl vom 03.11.).

Vorab festgelegt sind drei Hypothesen:

- **H1:** Rotation ist bei 2 Bit nicht besser.
- **H2:** Das kleinere Modell wird mit längerem Training relativ besser.
- **H3:** Die Rangfolge nach der Aufgabe weicht von der Rangfolge nach bpc ab.

Das Ergebnis „alle gleich“ ist ausdrücklich zugelassen. Beide Läufe gehen über die Sitzung „raven01-synchronous-rossum“ an den MPCDF-Cluster.

4. Was das für die Jugend-forscht-Arbeit bedeutet

- Die Arbeit stützt sich wohl nicht auf „Quanten-Trick schlägt alles“. Sie stützt sich auf zwei andere Punkte:
  (1) eine **saubere, byte-faire Methodik und Messreihe** an kleinen Modellen, also genau die Lücke aus S-003;
  (2) den Befund, dass **quanten-inspirierte Konstruktionen** (Clifford-Orbit-Codebuch, Hadamard) **gleichwertig mit den besten klassischen Verfahren** sind.
- Das ist ehrlich, für eine Jury gut erklärbar und auch dann vorzeigbar, wenn am Ende „alle gleich“ herauskommt.

5. Offen / nächste Schritte

- **Ergebnisse von I-050 und I-051 vom Cluster abholen.** Im Repo liegt noch nichts unter `INSTITUT/ergebnisse/I-050/` und `I-051/`. Danach kommen die Einträge in LABORBUCH und `agenda.json`.
- **W1 (Energie):** Du wolltest noch `ls /sys/class/powercap` am PC prüfen, ob RAPL verfügbar ist. Da es kein Steckdosen-Messgerät gibt, wird die Energie nur relativ gemessen.
- **Anmeldung bis 30.11.2026:** Bis dahin sollen Thema und Kernaussage stehen. Bis Mitte Dezember soll die W2-Messreihe vollständig sein, ab Januar wird nur noch geschrieben.
- Für spätere Runden noch offen: W3 (strukturierte FFN), W8 (Seed-Gewichte), W9 (MERA/Wavelet).

Kleines Glossar

Quantisierung	Gewichte mit wenigen Bits speichern, z. B. 2 statt 32 Bit, und so Speicher sparen.
bpw / bpc	Bits pro Gewicht (Speicherkosten) bzw. Bits pro Zeichen (Fehler des Sprachmodells, kleiner ist besser).
Hadamard-Rotation	Eine feste, unitäre Mischung der Gewichte, wie ein Quantengatter. Sie verteilt Ausreißer gleichmäßig.
Gruppenskala g16	Je 16 Gewichte bekommen einen eigenen Skalenfaktor. Das ist genau, kostet aber zusätzliche Bytes.
Lloyd / E8 / Orbit-8D	Verschiedene Codebücher: Lloyd ist optimal in 1D, E8 ist das dichteste Gitter in 8D, Orbit-8D ist das Codebuch aus Clifford-artiger Symmetrie.
Tuning- / Mess-Seeds	Mit Tuning-Seeds wird ausprobiert. Mess-Seeds werden nur im vorregistrierten Lauf benutzt, damit nichts schöngerechnet wird.
Vorregistrierung	Hypothesen und Auswertung werden *vor* dem Lauf festgeschrieben.
TOST	Statistischer Test auf Gleichwertigkeit, ob zwei Werte innerhalb einer Toleranz liegen.